Estudio sobre Sistemas de Recomendación y Predicción basados en el procesamiento del lenguaje natural

Hugo Ferrando Seage

25 de julio de 2017

Universidad Europea de Madrid
Escuela de Arquitectura, Ingeniería y Diseño

Introducción

Introducción

Los recomendadores son una parte esencial de cualquier servicio de Video on Demand (VOD). Tanto Netflix como Movistar+, Amazon, Hulu y HBO cuentan con sus propios sistemas.

También existen webs que usan sus recomendadores, como IMDb o FilmAffinity. Incluso existen servicios comerciales que se dedican a productivizar su sistema de recomendación, como Jinni.

Introducción

Existen tres grandes tipos de sistemas de recomendación:

- Filtrado Colaborativo
- Filtrado por contenido
- Sistemas híbridos

Filtrado Colaborativo

Consiste en emparejar usuarios que tengan gustos similares y recomendar en base a esos datos.

Normalmente se representa usando una matriz bidimensional donde las filas representan usuarios y la columnas representan productos.

Los usuarios deben puntuar los contenidos, o se pueden usar otras métricas.

Filtrado por Contenido

Consiste en la creación de un modelo que determina la similitud entre productos en base a algún criterio.

Ese criterio puede ser cualquier elemento del producto. Para películas puede ser el género. Para restaurantes el tipo de cocina. Etc.

Filtrado Híbrido

Usan una combinación de ambas técnicas para complementar las recomendaciones.

Objetivos

Objetivos

- Construir un recomendador de películas
- Crear el modelo en base a tres algoritmos
  - LSA
  - Doc2Vec
  - E-Modelo
- Optimizar modelos
- Crear una interfaz desde donde poder probarlos

Metodología

Metodología

La metodología usada ha sido ágil, basada en MVPs.

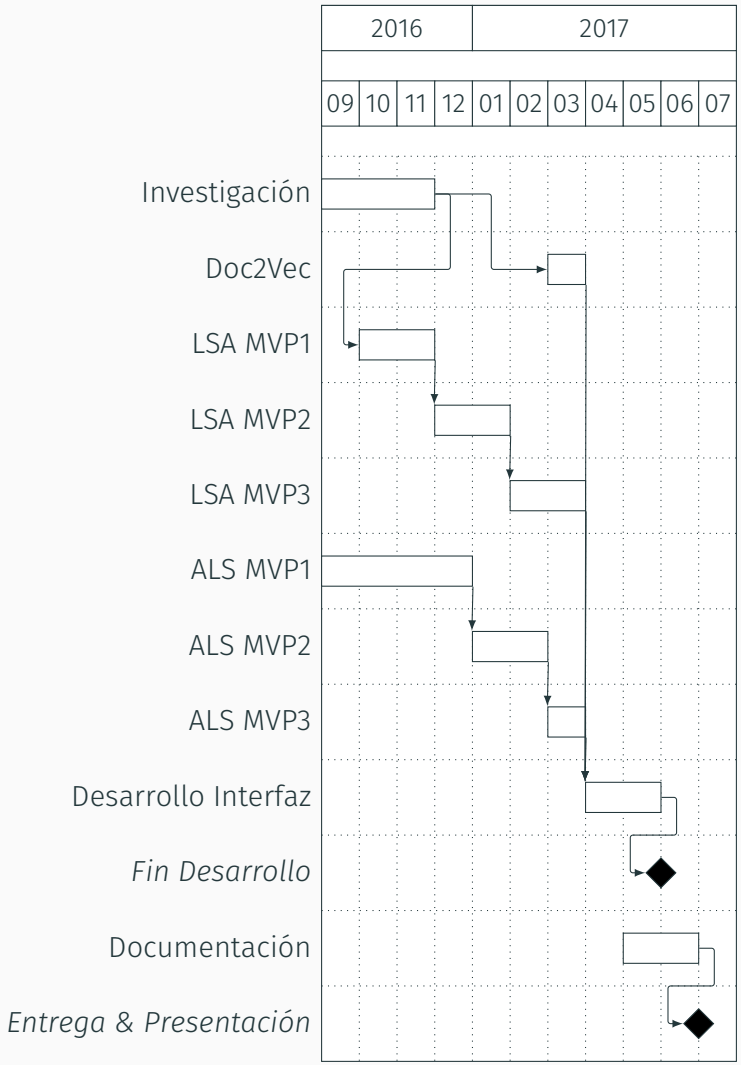

Descarga de datos

Descarga de datos

Para entrenar los modelos es necesario obtener una gran cantidad de textos. Para ello se ha creado un crawler usando Spidy, que descarga información y críticas de las top 1000 películas de IMDb.

Descarga de datos

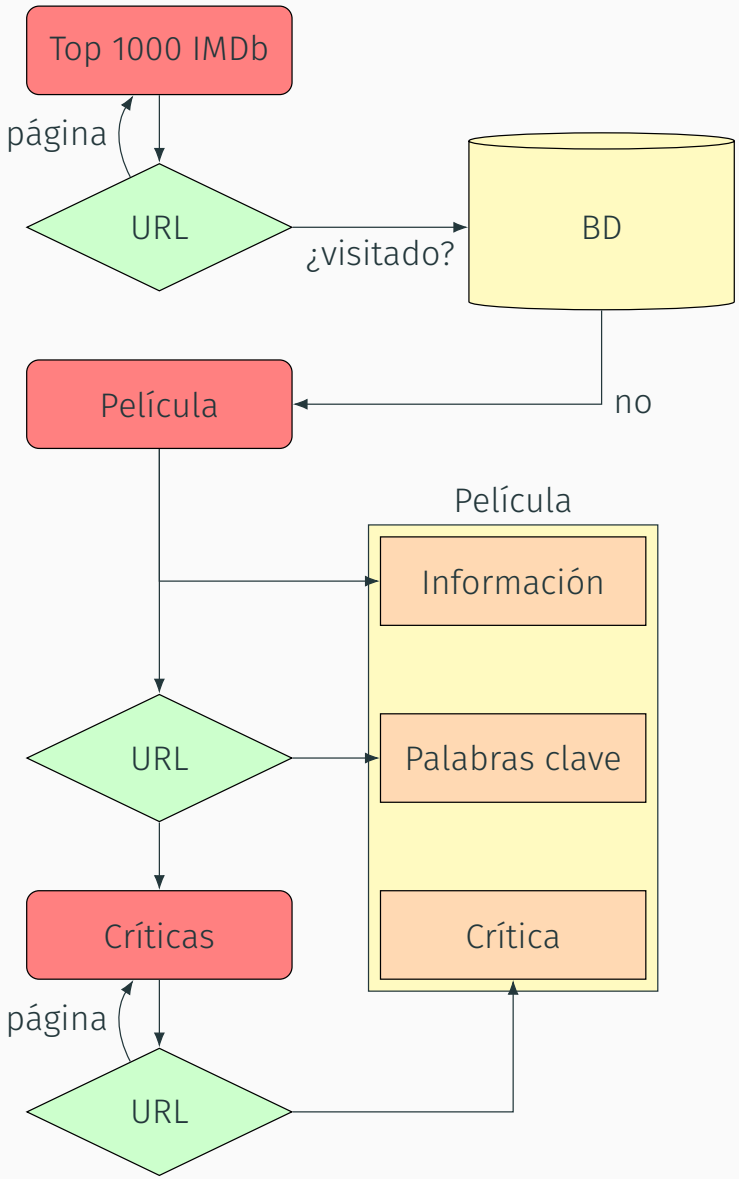

Limpieza de textos

Limpieza de textos

Antes de crear los modelos es necesario hacer un pretratado de los textos.

Ejemplo

```
Zeus is a Greek God.
```

POS Tagger

NNP	VBZ	DT	NN	NNP	
Zeus	is	a	Greek	God	.

Hiperónimos

```
Zeus is a country deity.
```

Nombres propios

Es necesario eliminar los nombres propios para que no se relacionen películas con personajes que tienen el mismo nombre.

```
is a country deity.
```

Stopwords

```
country deity
```

Stemmer

```
counti deiti
```

LSA

LSA

Latent Semantic Analysis trata de extraer conceptos de cada texto y analizar la relación entre documentos.

TF-IDF

Term Frequency-Inverse Document Frequency calcula lo relevante que es cada palabra del vocabulario dentro de cada texto.

$$
tfidf = \begin{array}{r} \\ \text{The Matrix} \\ \text{Alien} \\ \text{Serenity} \\ \text{Casablanca} \\ \text{Amelie} \end{array}
\begin{array}{c}
\begin{array}{ccccccc} \text{says} & \text{just} & \text{room} & \text{dead} & \text{asks} & \text{ship} & \text{mother} \end{array} \\
\begin{pmatrix}
0{,}39 & 0{,}16 & 0{,}19 & 0{,}01 & 0{,}25 & 0{,}79 & 0{,}27 \\
0{,}12 & 0{,}12 & 0{,}06 & 0{,}46 & 0{,}21 & 0{,}07 & 0{,}83 \\
0{,}46 & 0{,}55 & 0{,}15 & 0{,}55 & 0{,}22 & 0{,}27 & 0{,}11 \\
0{,}00 & 0{,}60 & 0{,}51 & 0{,}00 & 0{,}00 & 0{,}60 & 0{,}00 \\
0{,}41 & 0{,}00 & 0{,}35 & 0{,}83 & 0{,}00 & 0{,}00 & 0{,}00
\end{pmatrix}
\end{array}
$$

SVD

El siguiente paso es descomponer la matriz en valores singulares.

Matriz Palabra-Concepto.

$$
U = \begin{array}{c} \\ \text{action} \\ \text{gun} \\ \text{shoot} \\ \text{run} \\ \text{love} \\ \text{peace} \\ \text{kiss} \end{array}
\begin{array}{c}
\begin{array}{ccc} \text{Sci-Fi topic} & \text{Romance topic} & \text{Ruido} \end{array} \\
\begin{pmatrix}
0{,}13 & 0{,}02 & -0{,}01 \\
0{,}41 & 0{,}07 & -0{,}03 \\
0{,}55 & 0{,}09 & -0{,}04 \\
0{,}68 & 0{,}11 & -0{,}05 \\
0{,}15 & -0{,}59 & 0{,}65 \\
0{,}07 & -0{,}73 & 0{,}67 \\
0{,}07 & -0{,}29 & 0{,}32
\end{pmatrix}
\end{array}
$$

Matriz de relevancia de Conceptos.

$$\Sigma = \begin{array}{c} \begin{array}{ccc} \text{Sci-Fi topic} & \text{Romance topic} & \text{Ruido} \end{array} \\ \begin{pmatrix} 12{,}4 & 0 & 0 \\ 0 & 9{,}5 & 0 \\ 0 & 0 & 1{,}3 \end{pmatrix} \end{array}$$

Matriz Película-Concepto.

$$
V^T = \begin{array}{r} \\ \text{Sci-Fi topic} \\ \text{Romance topic} \\ \text{Ruido} \end{array}
\begin{array}{c}
\begin{array}{ccccc} \text{Matrix} & \text{Alien} & \text{Serenity} & \text{Casablanca} & \text{Amelie} \end{array} \\
\begin{pmatrix}
0{,}56 & 0{,}59 & 0{,}56 & 0{,}09 & 0{,}09 \\
0{,}12 & -0{,}02 & 0{,}12 & -0{,}69 & -0{,}69 \\
0{,}40 & -0{,}80 & 0{,}40 & 0{,}09 & 0{,}09
\end{pmatrix}
\end{array}
$$

Los conceptos menos relevantes se pueden eliminar.

$$V^T = \begin{array}{r} \\ \text{Sci-Fi topic} \\ \\ \text{Romance topic} \end{array} \begin{array}{c} \begin{array}{ccccc} \text{Matrix} & \text{Alien} & \text{Serenity} & \text{Casablanca} & \text{Amelie} \end{array} \\ \begin{pmatrix} 0{,}56 & 0{,}59 & 0{,}56 & 0{,}09 & 0{,}09 \\ 0{,}12 & -0{,}02 & 0{,}12 & -0{,}69 & -0{,}69 \end{pmatrix} \end{array}$$

Similitud Coseno

$$\cos\left(\begin{pmatrix} 0{,}56 \\ \\ 0{,}12 \end{pmatrix}, \begin{pmatrix} 0{,}59 \\ \\ -0{,}02 \end{pmatrix}\right) = 0{,}97 \tag{1}$$

Figura 1: Alta similitud entre Matrix y Alien

$$\cos\left(\begin{pmatrix} 0{,}56 \\ \\ 0{,}12 \end{pmatrix}, \begin{pmatrix} 0{,}09 \\ \\ -0{,}69 \end{pmatrix}\right) = -0{,}08 \tag{2}$$

Figura 2: Baja similitud entre Matrix y Amelie

Doc2Vec

Word2Vec

Word2Vec es un algoritmo creado por Google en 2013. Es conceptualmente similar a LSA, pero teniendo en cuenta cada palabra dentro de su contexto.

Es decir, calcula la probabilidad de que una palabra esté en la vecindad de otra palabra en el vocabulario.

Word2Vec

En primer lugar se guardan las parejas de palabras dentro de una ventana.

Source Text	Training Samples
The quick brown fox jumps over the lazy dog	(‘the’, ‘quick’) (‘the’, ‘brown’)
The quick brown fox jumps over the lazy dog	(‘quick’, ‘the’) (‘quick’, ‘brown’) (‘quick’, ‘fox’)
The quick brown fox jumps over the lazy dog	(‘brown’, ‘the’) (‘brown’, ‘quick’) (‘brown’, ‘fox’) (‘brown’, ‘jumps’)
The quick brown fox jumps over the lazy dog	(‘fox’, ‘quick’) (‘fox’, ‘brown’) (‘fox’, ‘jumps’) (‘fox’, ‘over’)

Word2Vec

Las palabras del vocabulario se convierten a vectores one-hot.

Palabra	Posición por orden alfabético	Vector
fox	2/3	[0, 1, 0]
dog	1/3	[1, 0, 0]
zebra	3/3	[0, 0, 1]

Word2Vec

Con los datos obtenidos se entrena una red neuronal con una capa oculta.

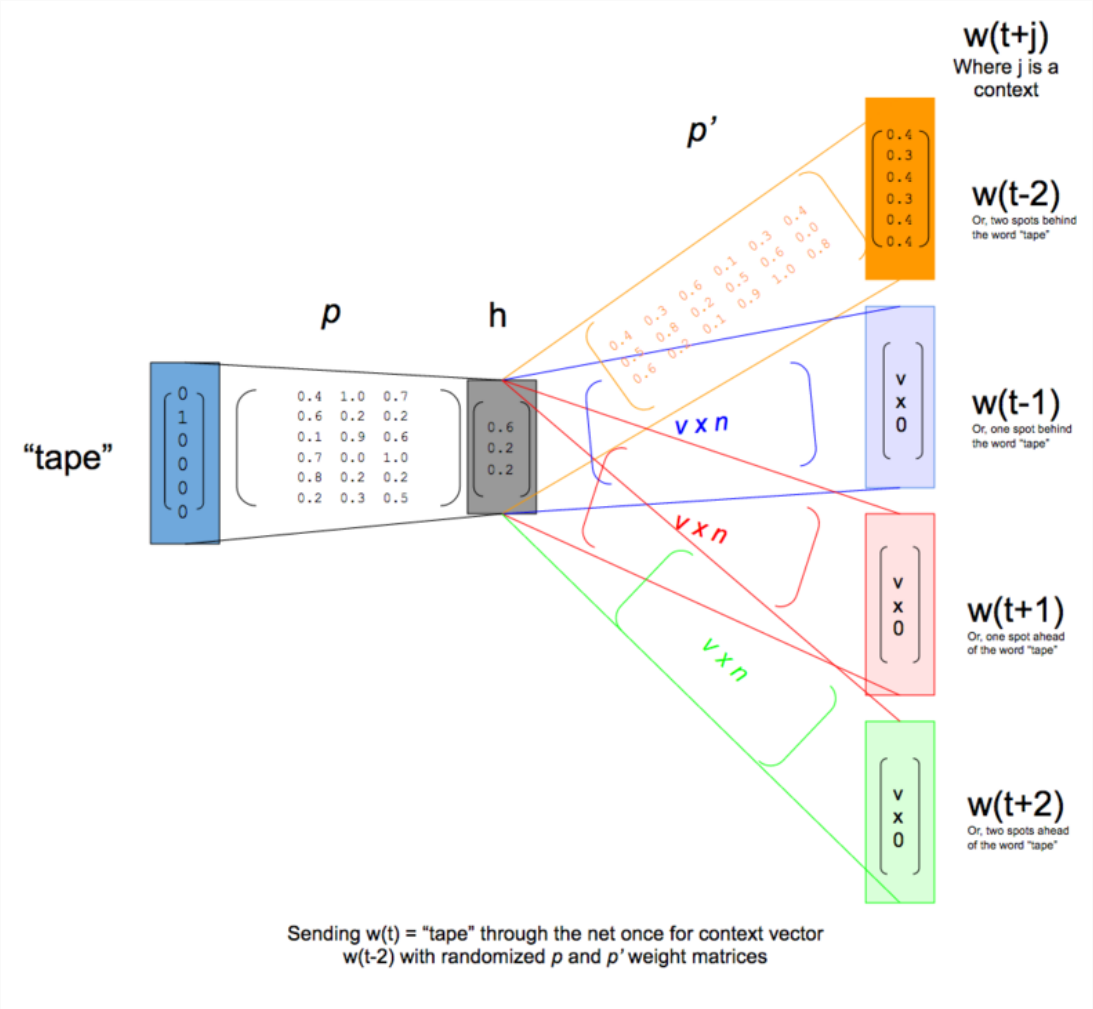

Word2Vec

La capa de input tiene tantas neuronas como palabras en el vocabulario. La función de activación es lineal.

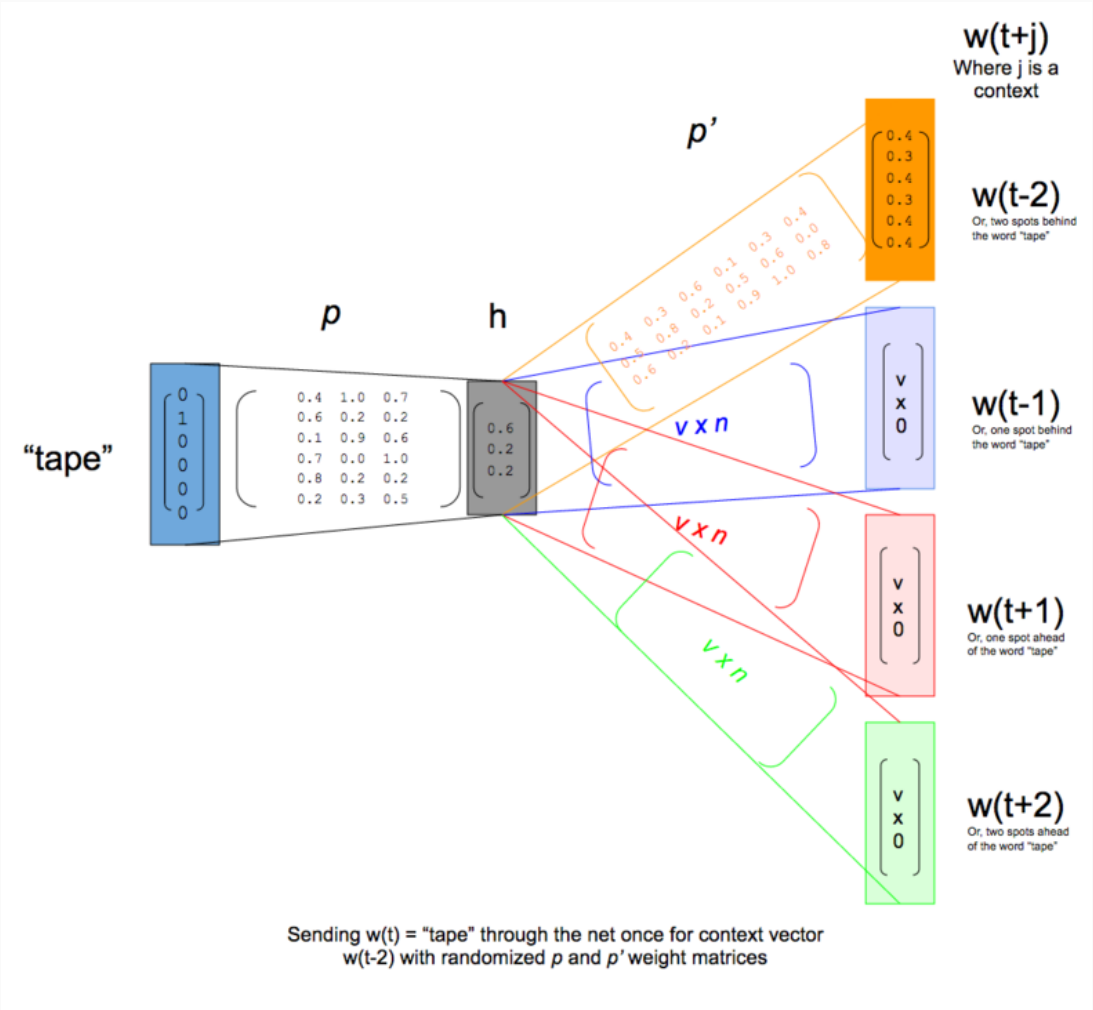

Word2Vec

h tiene tantas neuronas como componentes se quieran extraer.

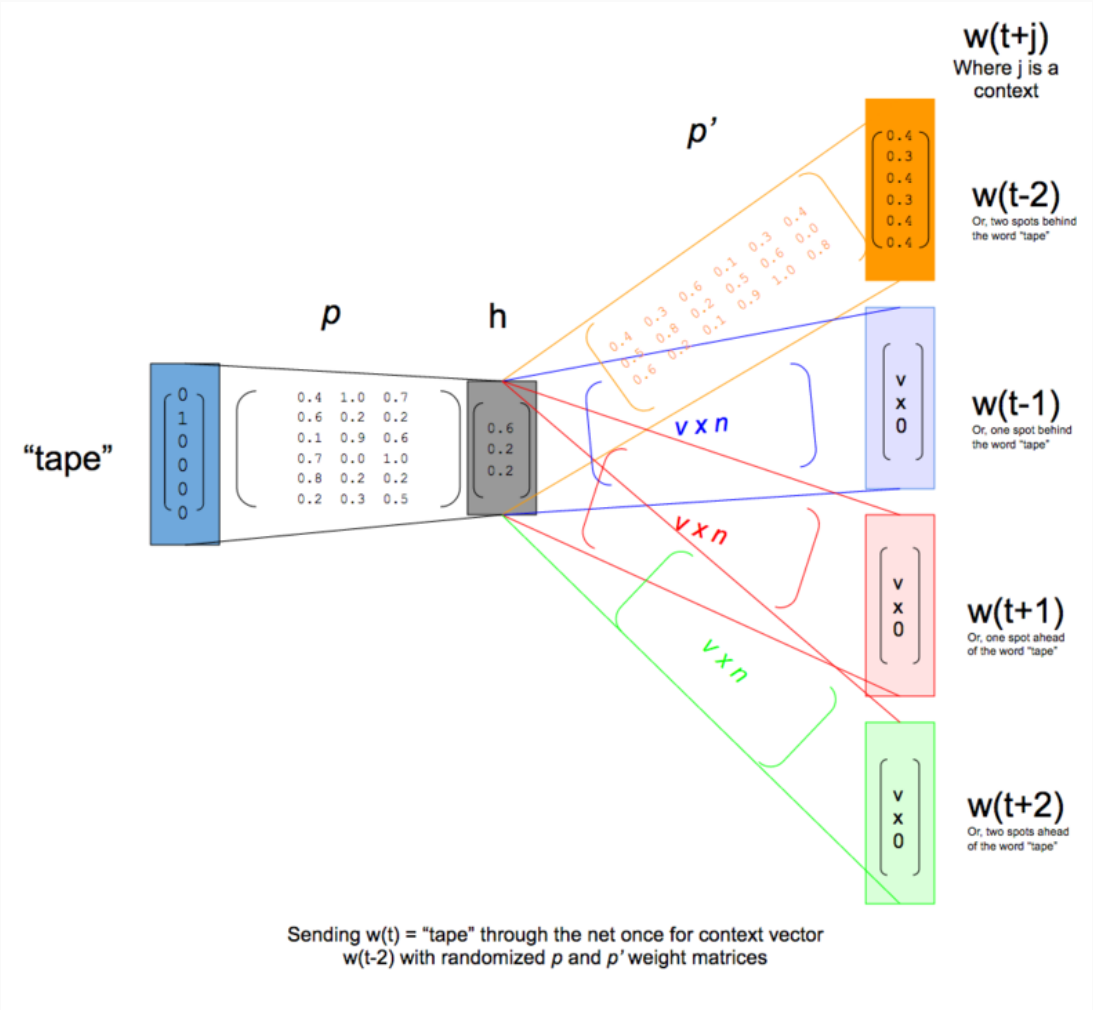

Word2Vec

La capa output tienen tantos vectores como el número de componentes de la ventana.

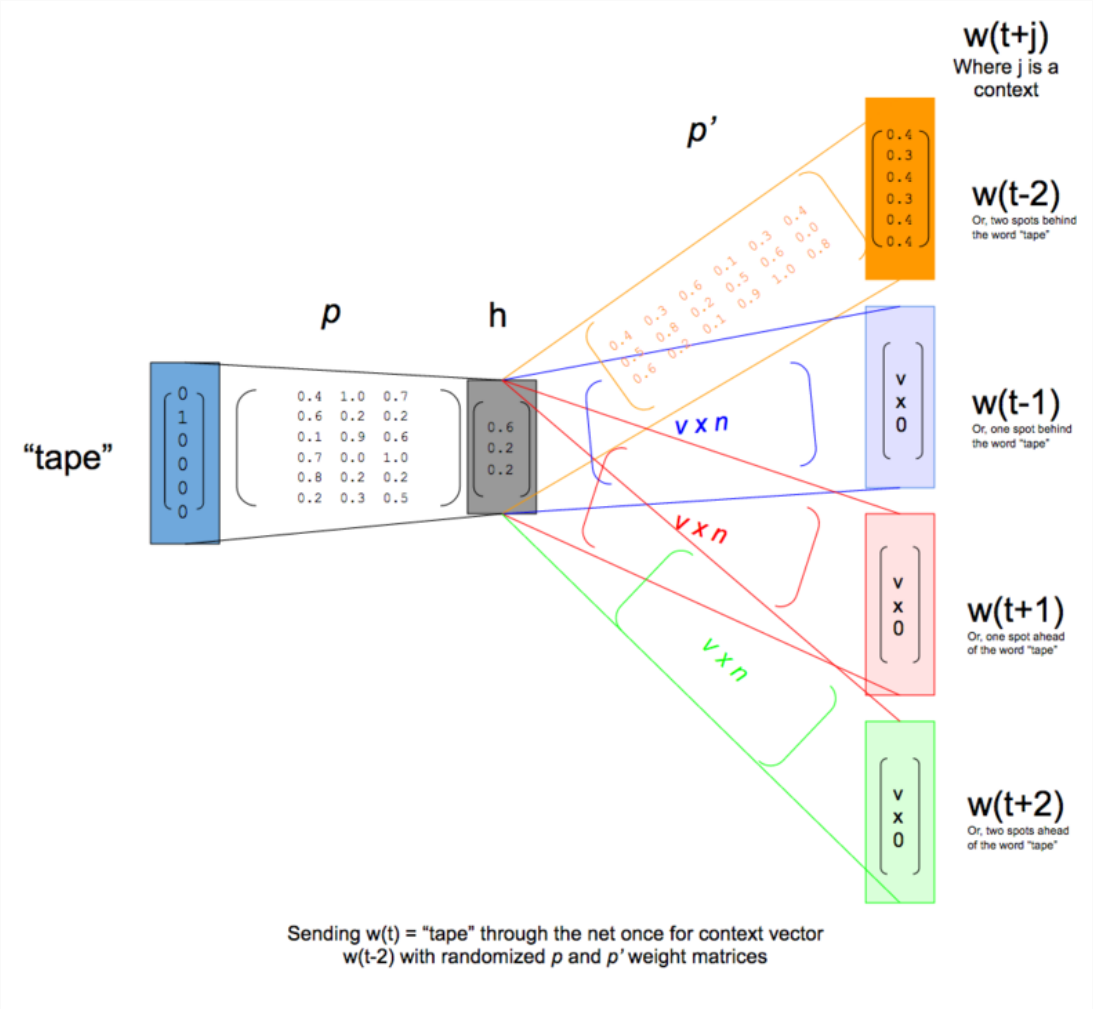

Word2Vec

Los resultados son vectores que se pueden comparar usando la similaridad del coseno de cada vector.

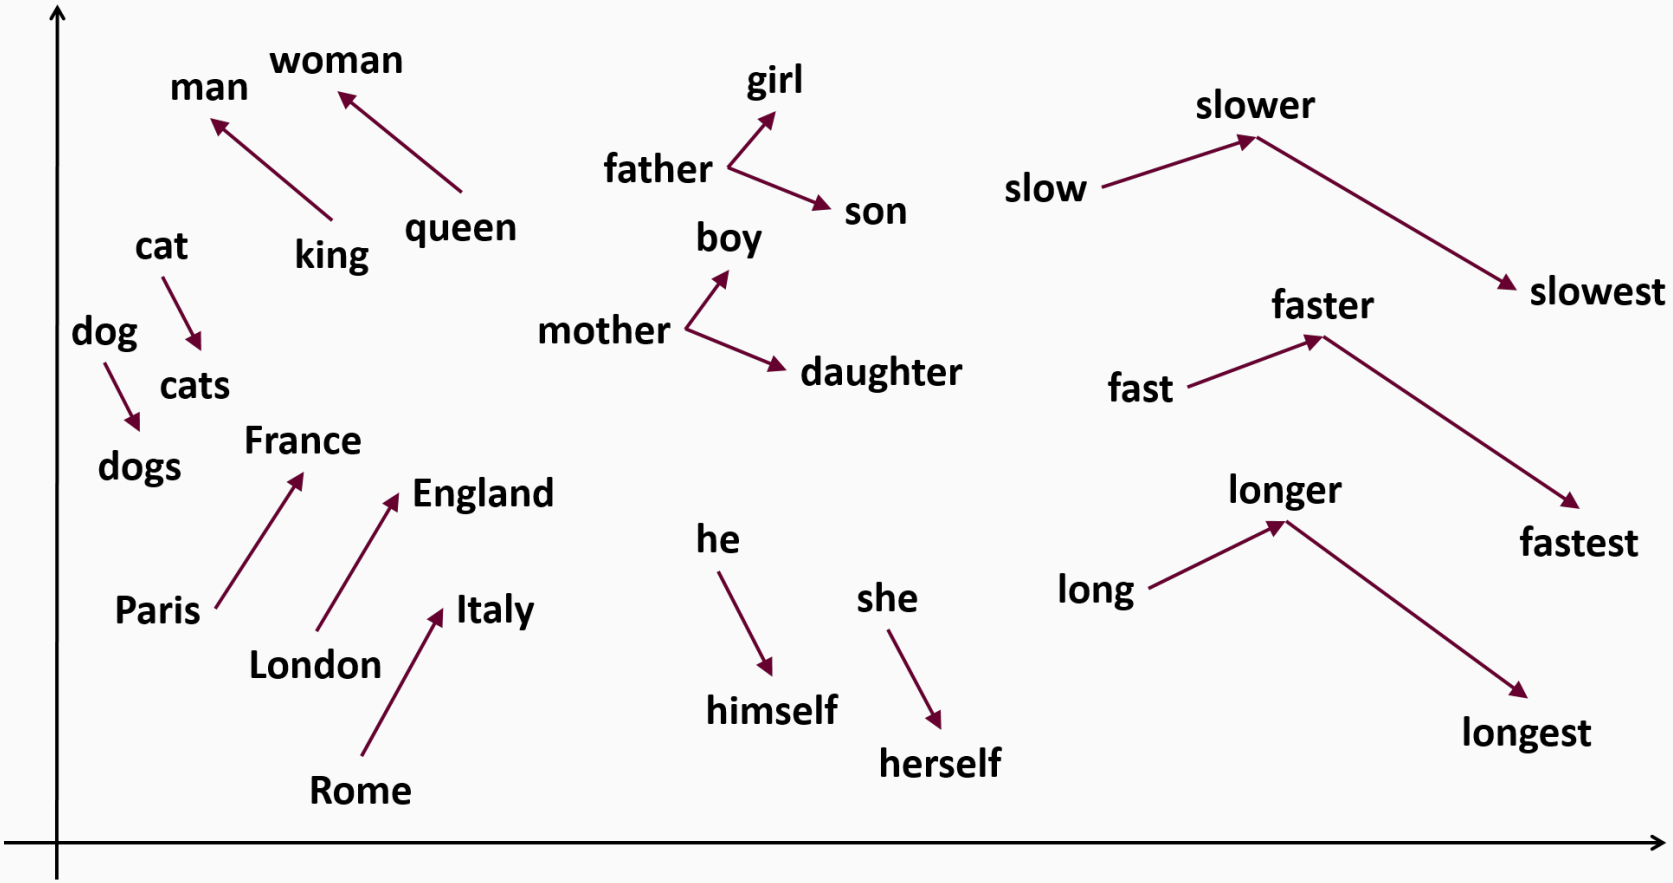

Word2Vec

Palabra clave	Palabras similares				
mafia	dealer	banker	mob	mexican	drug
axe	expedition	undercover	biker	employee	outlaw
hair	clothes	coat	eyes	teeth	makeup
airplane	announcer	sanctuary	engine	accident	ambushed
plant	retrieve	investigate	thwart	unearth	escape
air	automatic	oil	swinging	oxygen	ocean

Doc2Vec

Word2Vec trabaja a nivel de palabras. Doc2Vec extiende el algoritmo para hacer comparaciones entre documentos.

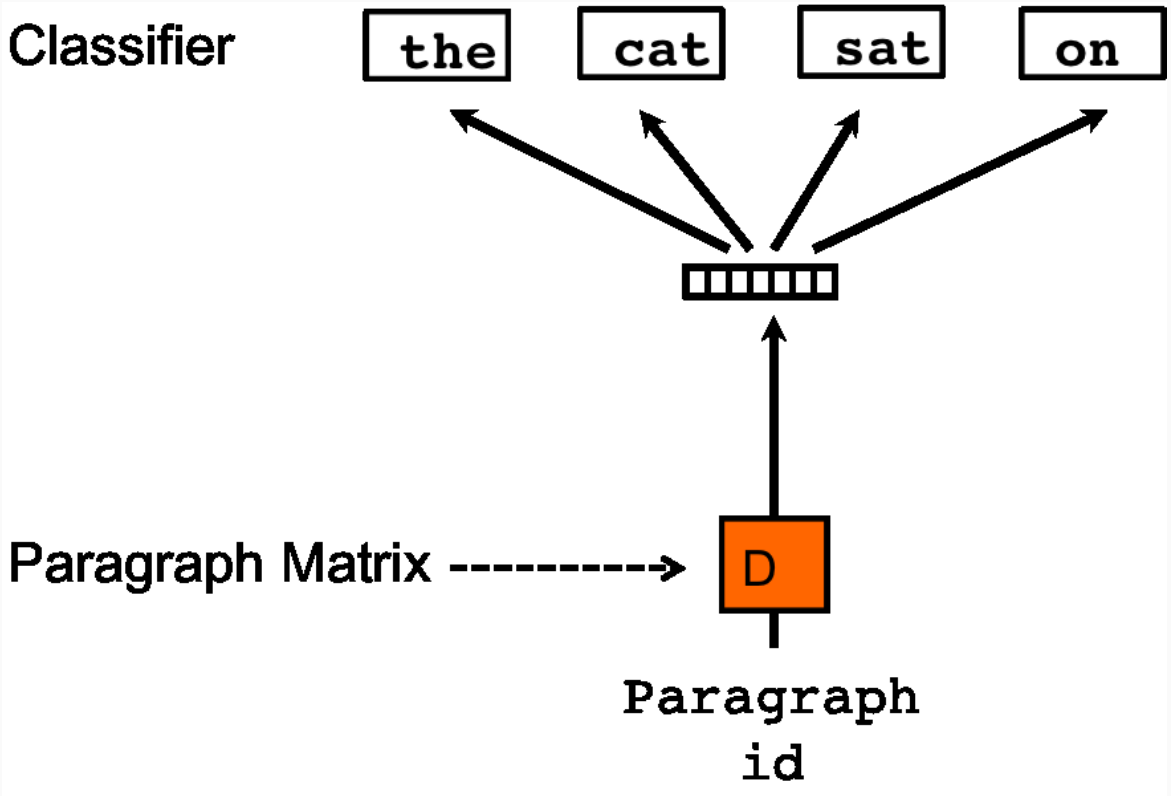

E-Modelo

E-Modelo

Modelo de predicción de tokens hibrido.

Combina el filtrado colaborativo con los features extraidos de un filtrado por contenido.

E-Modelo

En primer lugar extraemos tokens como se ha hecho en el pre-filtrado de textos.

En este caso se ha usado un servicio comercial llamado Bitext.

E-Modelo

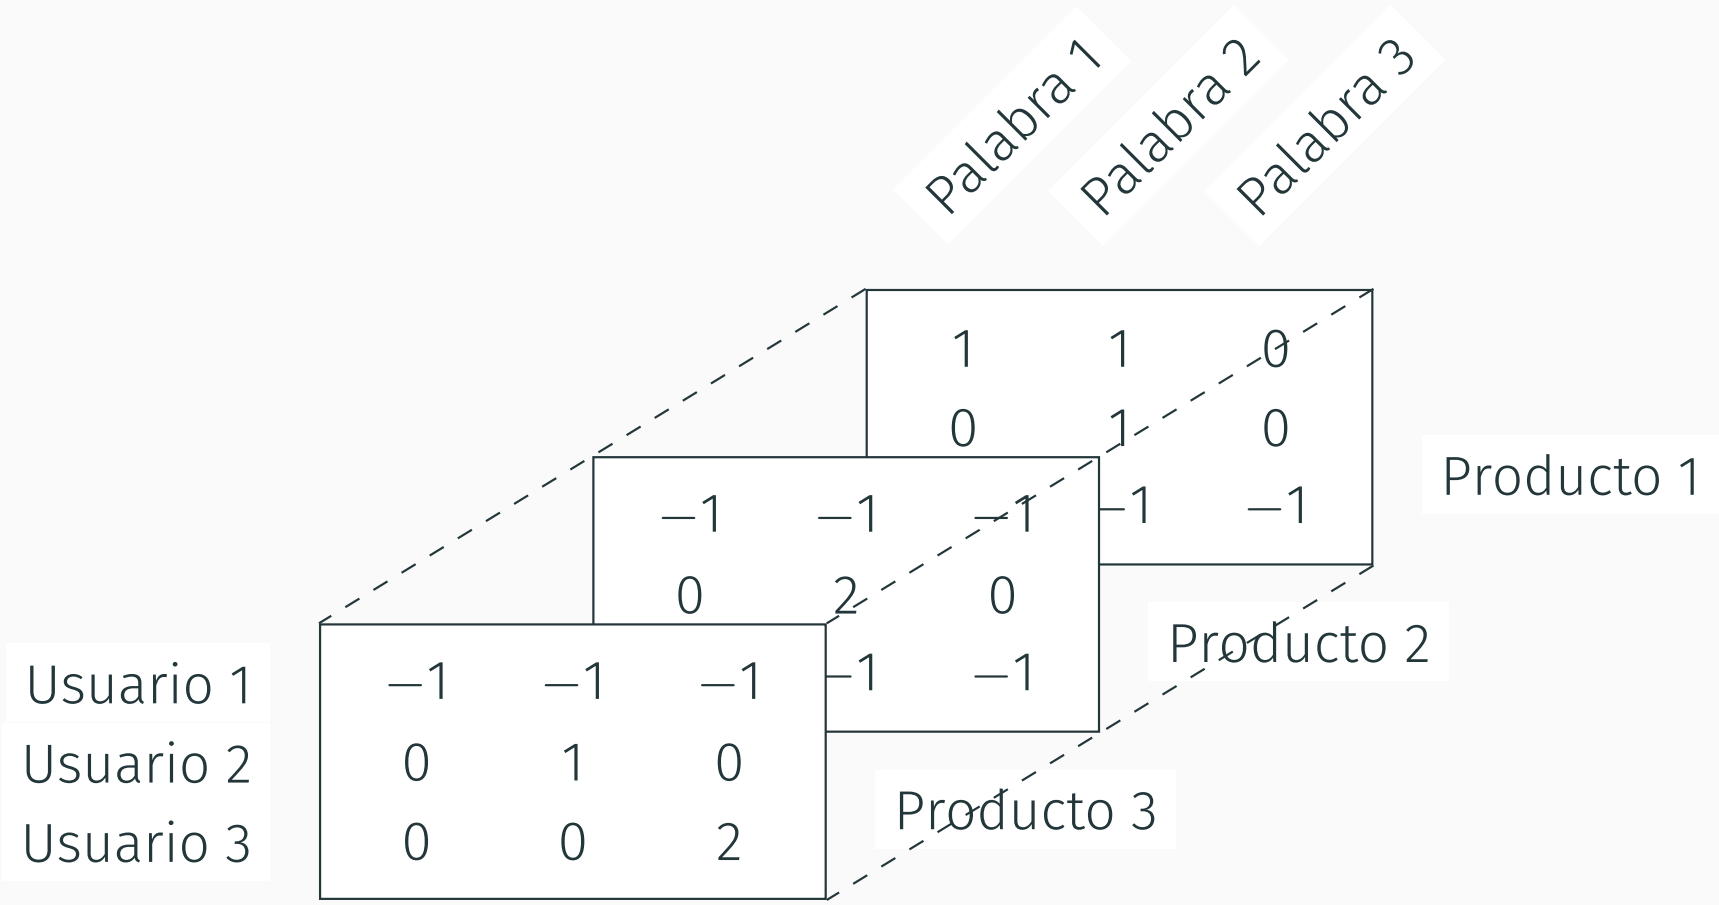
Palabra 1
Palabra 2
Palabra 3
Producto 1
Producto 2
Producto 3
Usuario 1
Usuario 2
Usuario 3
1 1 0
0 1 0
−1 −1
0 1 −1
−1 −1 −1
0 2 0
−1 −1
−1 −1 −1
0 1 0
0 0 2

E-Modelo

	Producto 1			Producto 2			Producto 3		
	Palabra 1	Palabra 2	Palabra 3	Palabra 1	Palabra 2	Palabra 3	Palabra 1	Palabra 2	Palabra 3
Usuario 1	1	1	0	−1	−1	−1	−1	−1	−1
Usuario 2	0	1	0	0	2	0	0	1	0
Usuario 3	−1	−1	−1	−1	−1	−1	0	0	2

Optimización

Optimización

Para cada modelo hay unos parámetros que se pueden ajustar.

Parámetros LSA

- Número de ‘features’ TF-IDF
- Número de componentes LSA
- Frecuencia Mínima de Documentos
- Frecuencia Máxima de Documentos

Parámetros Doc2Vec

- Size
- Window
- Minimum Word Count
- Iteraciones

Optimización LSA

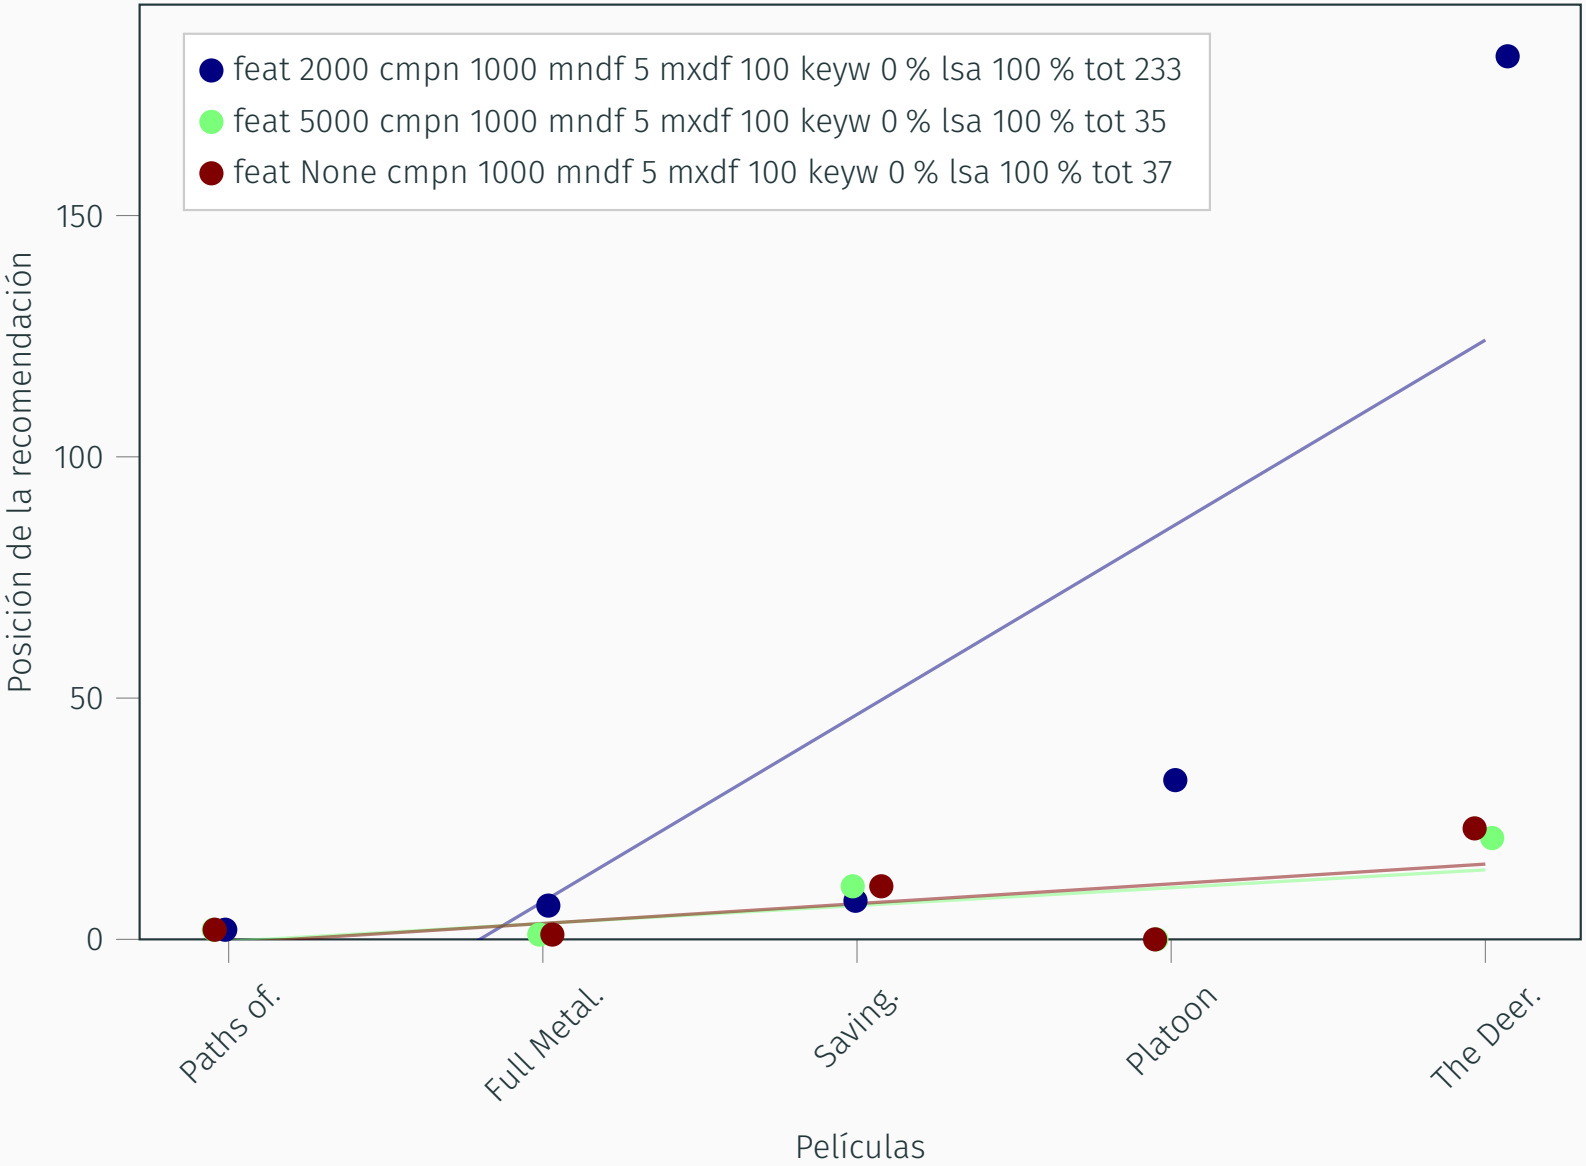

Optimización LSA

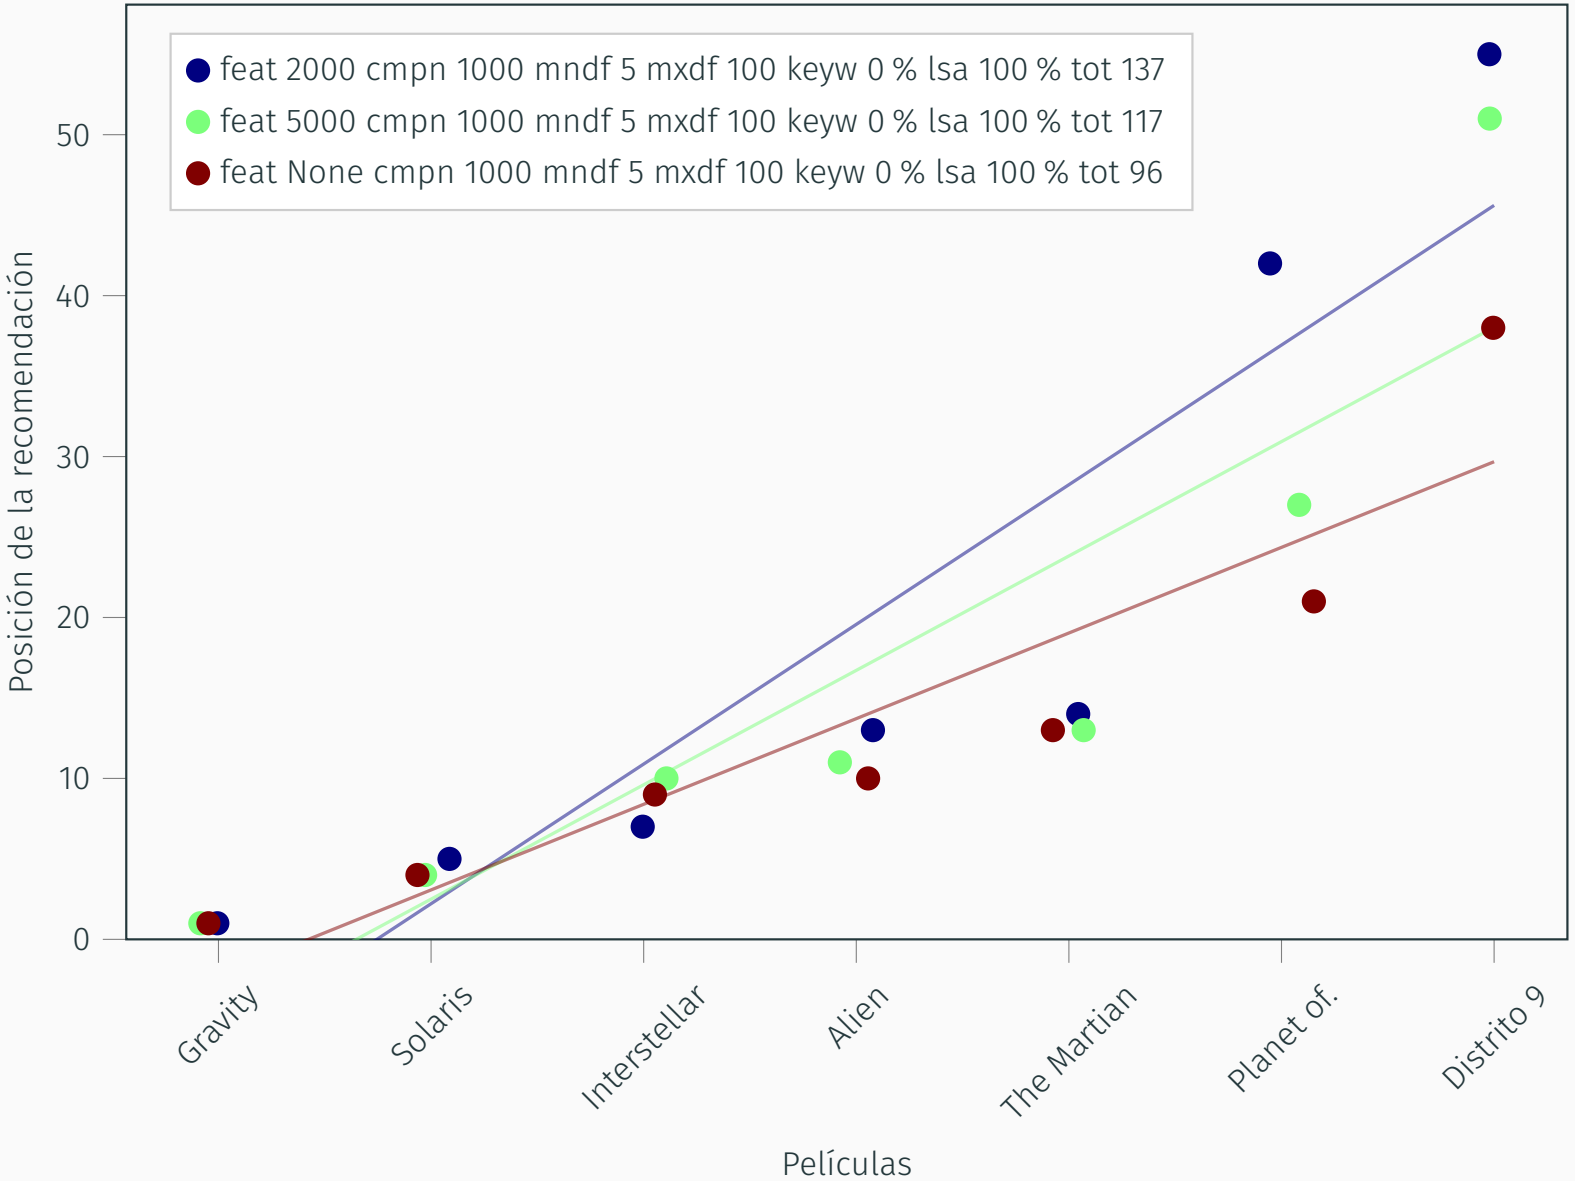

Optimización LSA

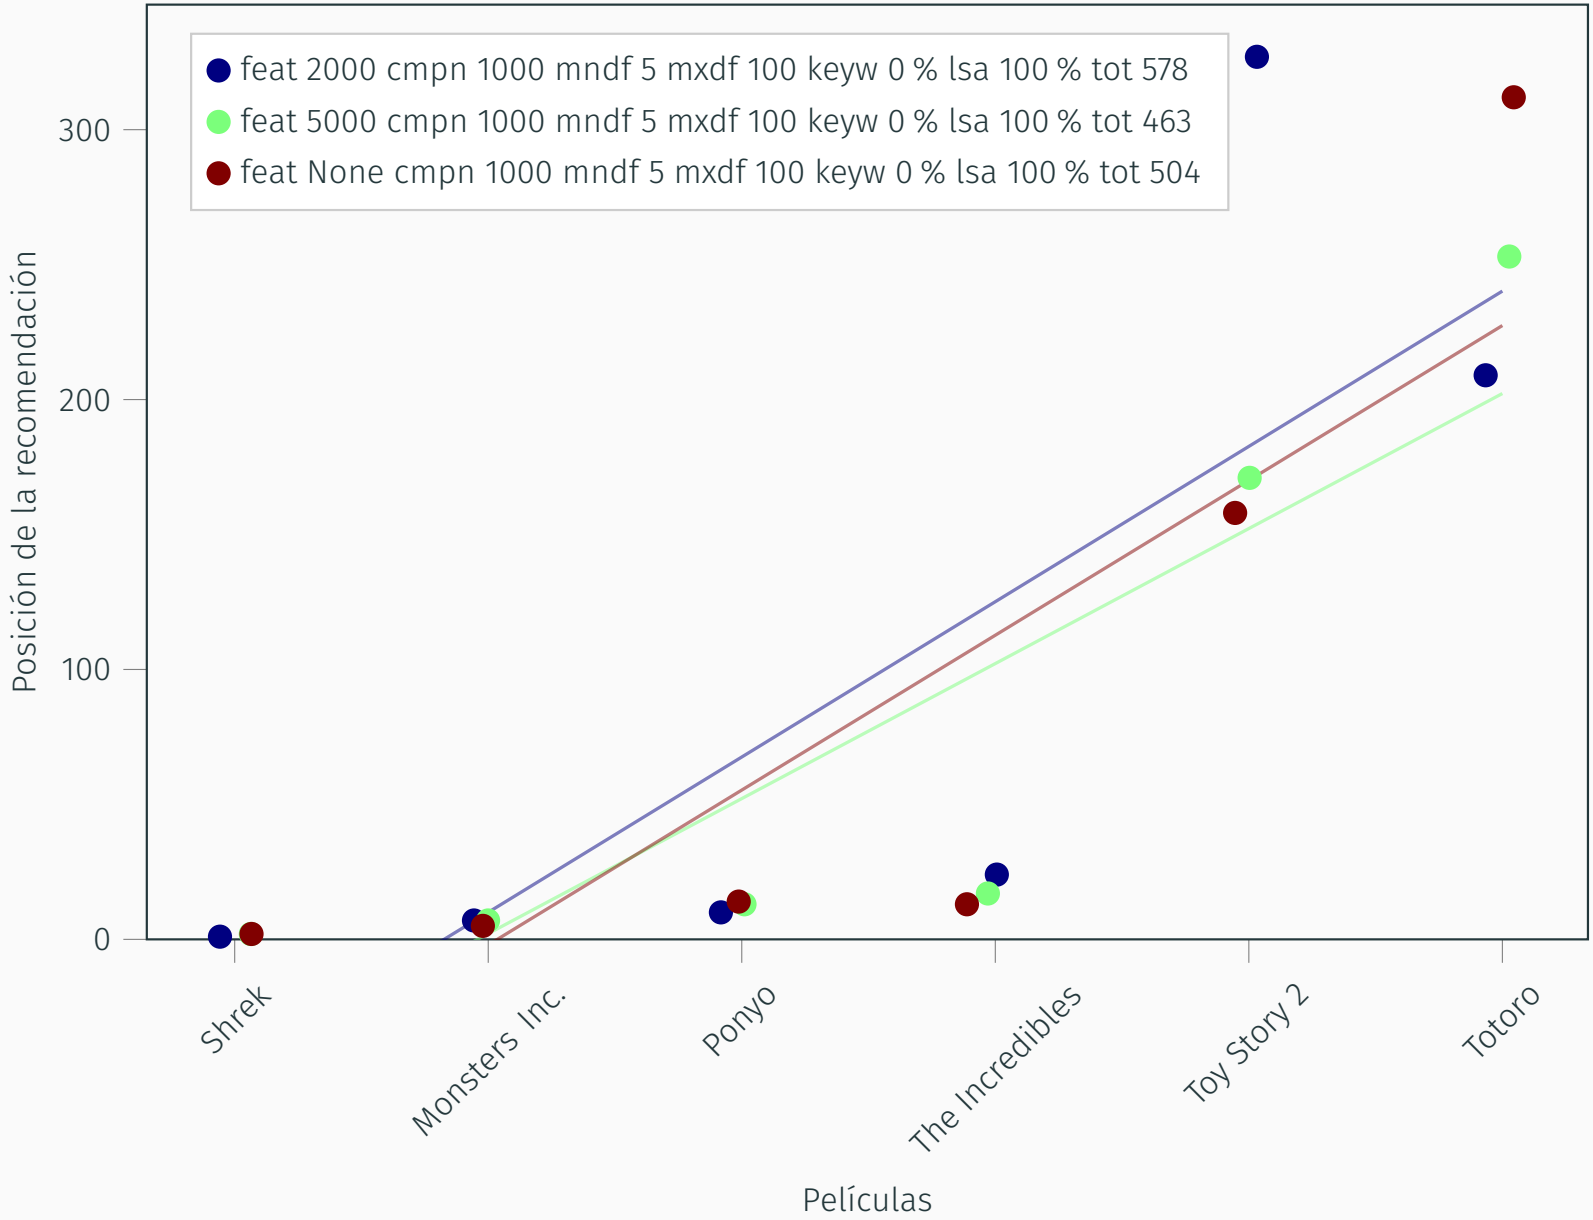

Optimización Doc2Vec

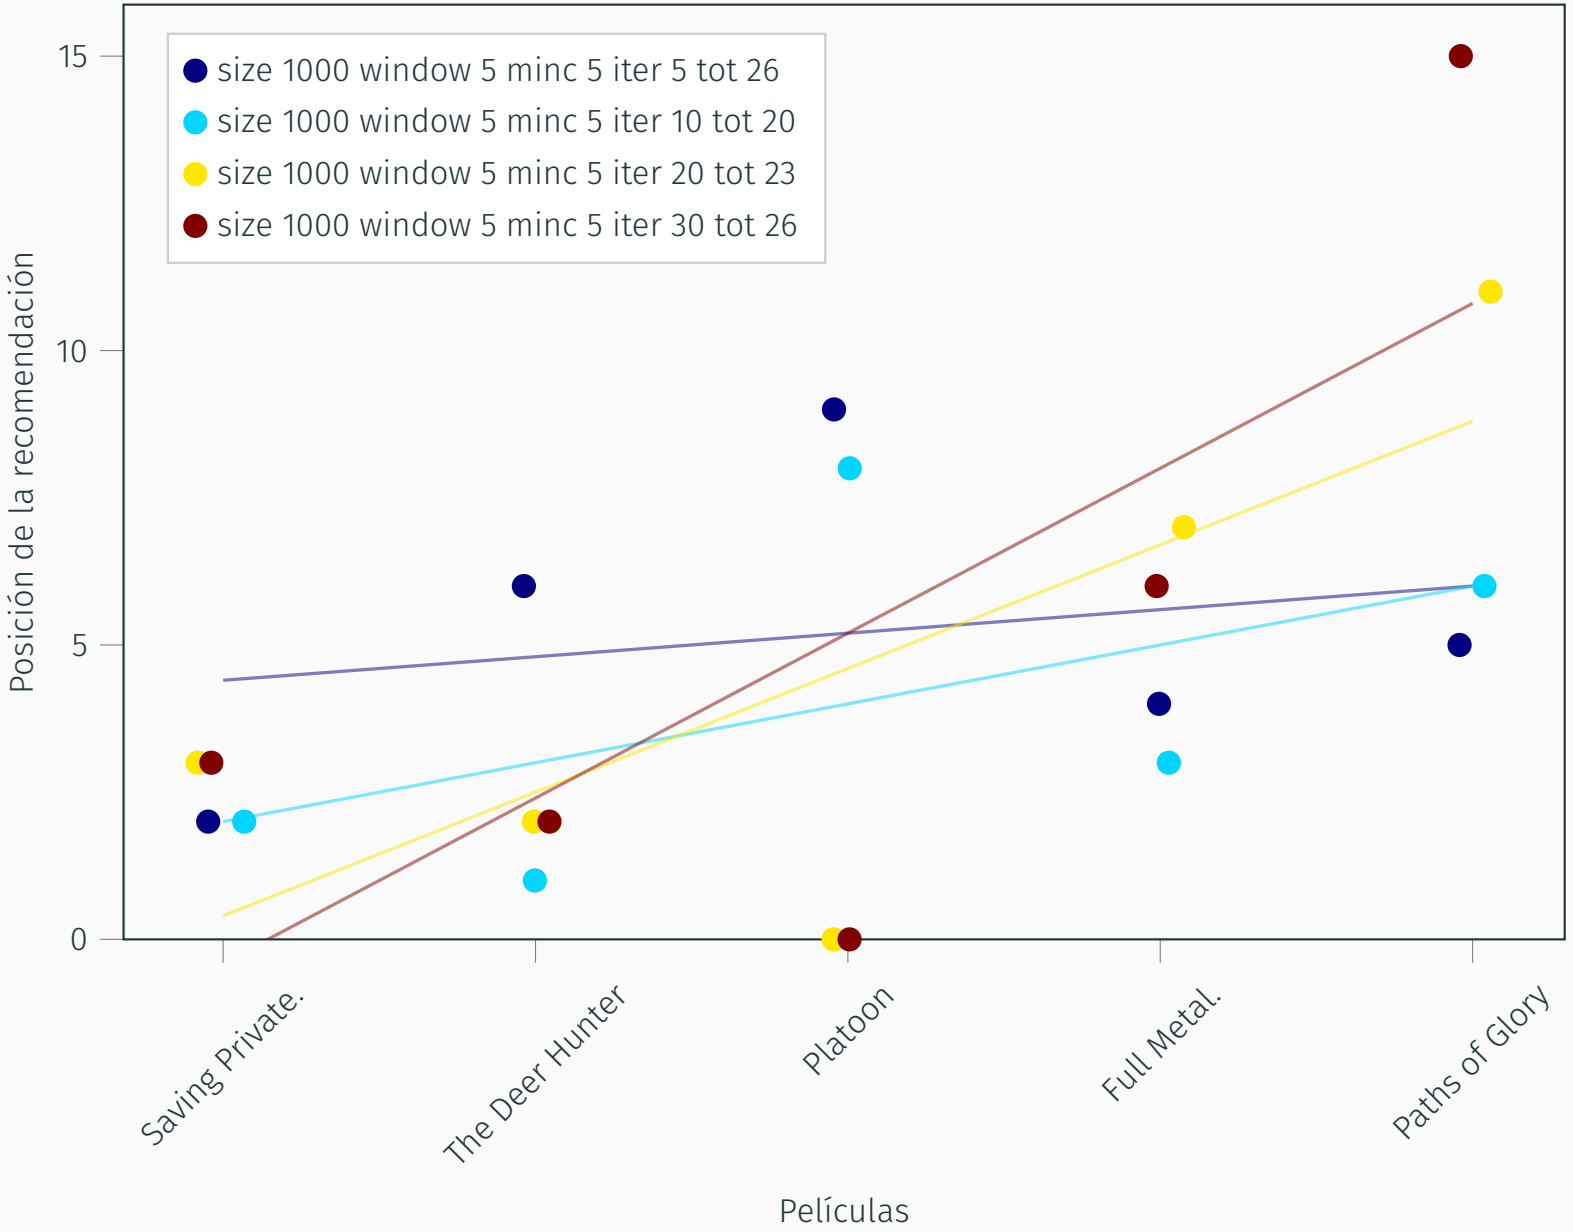

Optimización Doc2Vec

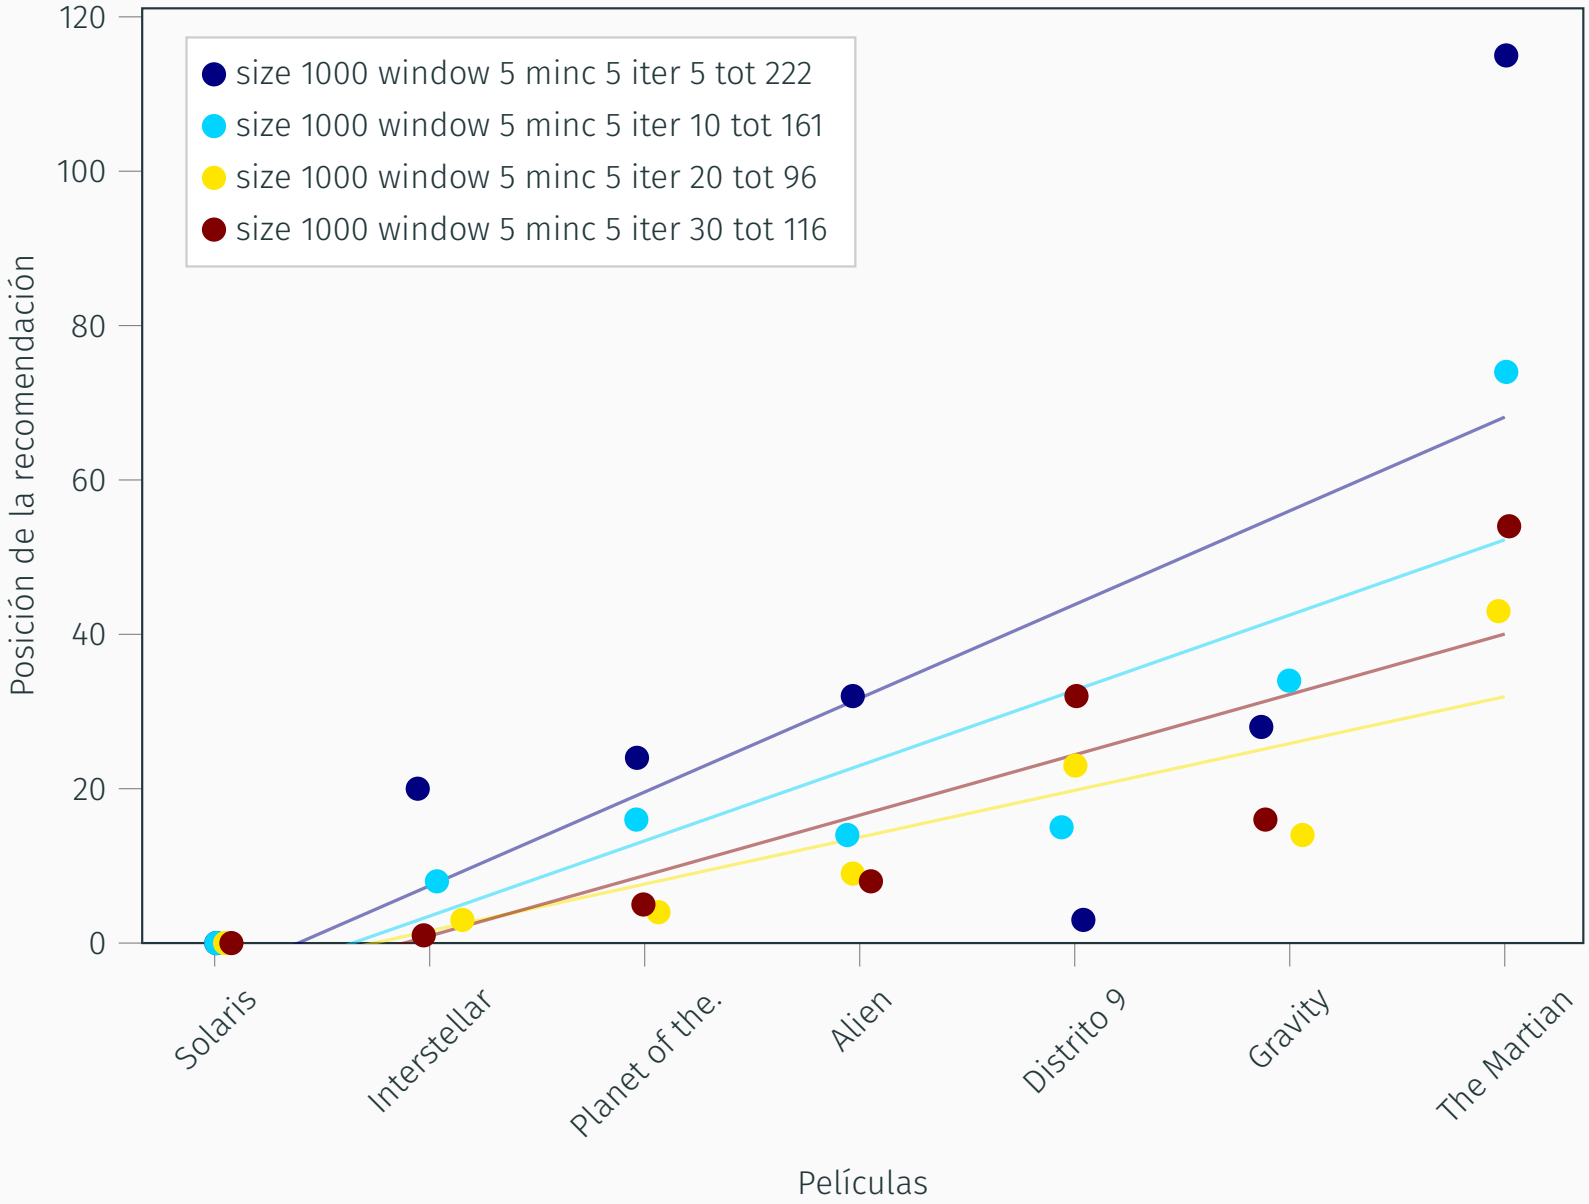

Optimización Doc2Vec

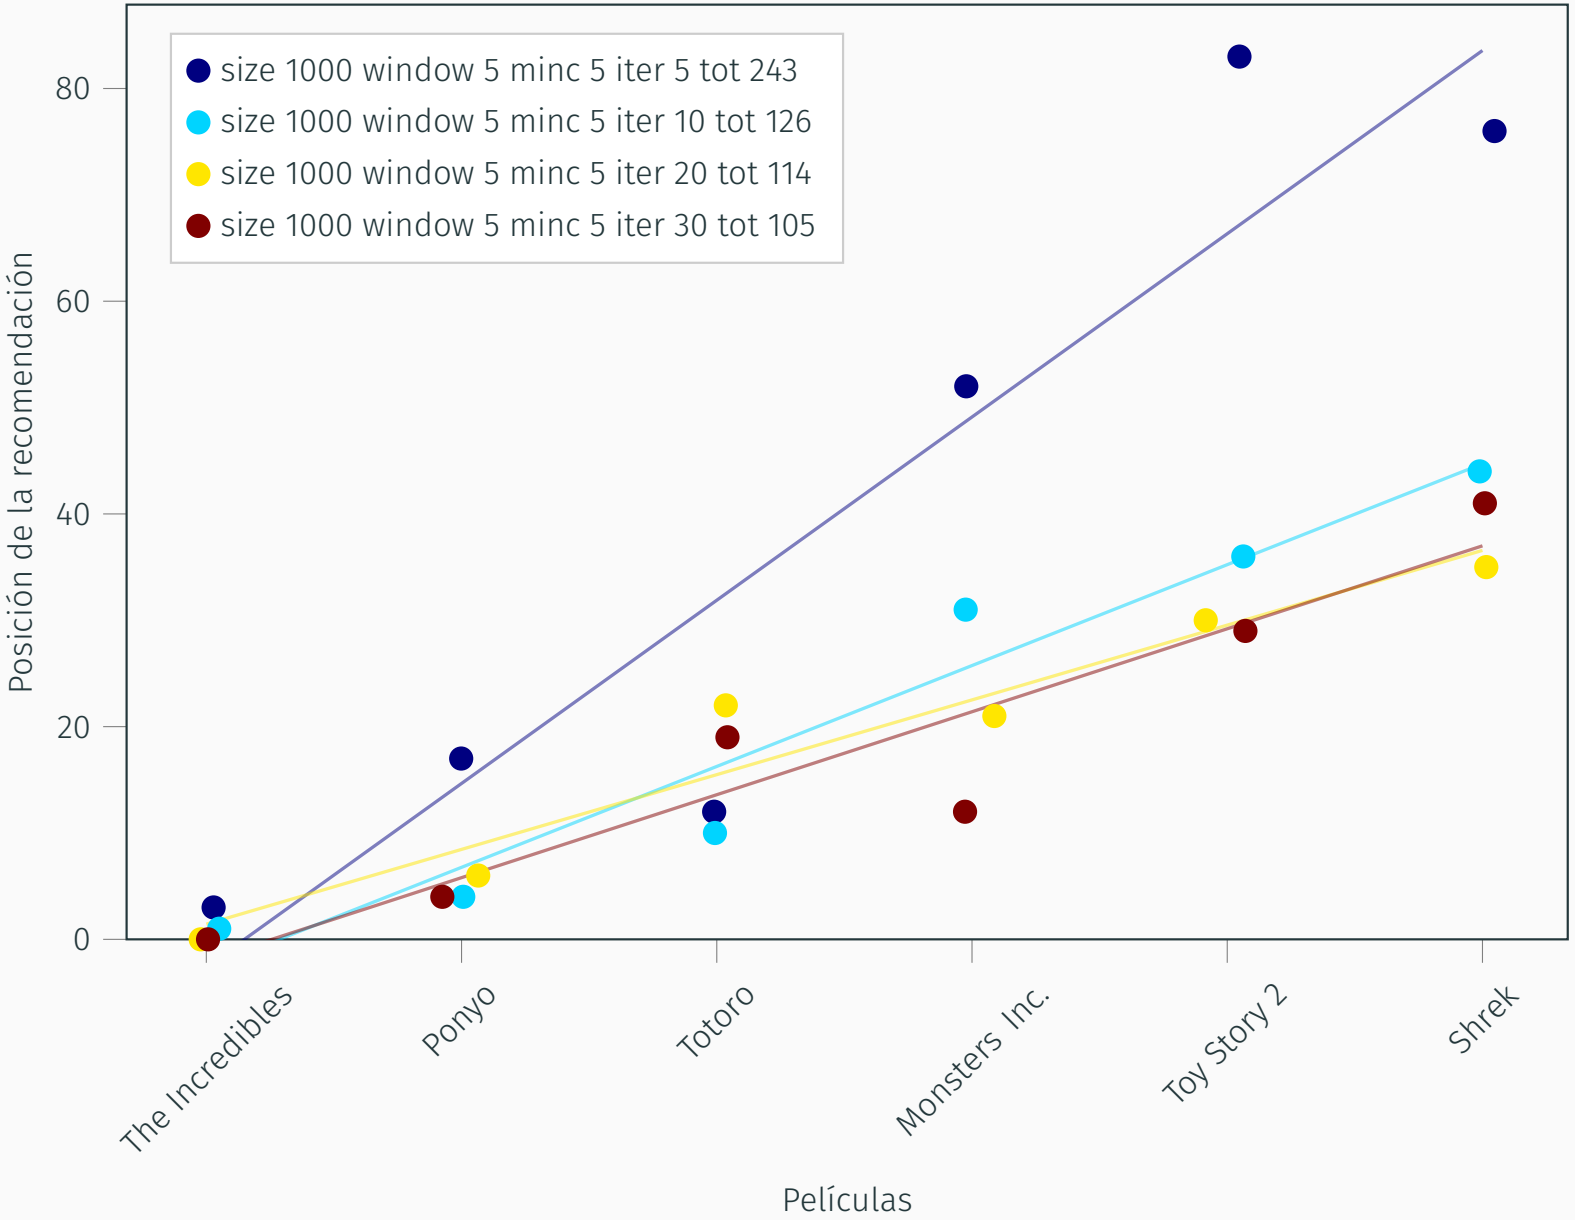

Demo

Demo

https://moviepepper.hugofs.com